Московский авиационный институт (национальный исследовательский университет)

Институт №8 «Информационные технологии и прикладная математика»

Кафедра 806 «Вычислительная математика и программирование»

Лабораторная работа №1 по курсу «Нейроинформатика»

Студент: В.В. Бирюков Преподаватель: И.А. Рожлейс

Группа: М8О-407Б-19

Дата: Оценка: Подпись:

Лабораторная работа №1

Тема: Персептроны. Процедура обучения Розенблатта.

Цель работы: Исследование свойств персептрона Розенблатта и его применение для решения задачи распознавания образов.

Основные этапы работы:

- 1. Для первой обучающей выборки построить и обучить сеть, которая будет правильно относить точки к двум классам. Отобразить дискриминантную линию и проверить качество обучения.
- 2. Изменить обучающее множество так, чтобы классы стали линейно неразделимыми. Проверить возможности обучения по правилу Розенблатта.
- 3. Для второй обучающей выборки построить и обучить сеть, которая будет правильно относить точки к четырем классам. Отобразить дискриминантную линию и проверить качество обучения.

Вариант: 9

Data	Labels
$\begin{bmatrix} -1.1 & 1.8 & 4.8 & 1.2 & -1.2 & 2.5 \\ -4.3 & -1 & -1 & -3.5 & -3.4 & 3.7 \end{bmatrix}$	$\begin{bmatrix} 0 & 1 & 1 & 1 & 0 & 1 \end{bmatrix}$
$\begin{bmatrix} 4.6 & -1 & -0.3 & -1.1 & 0.5 & 4.9 & 0.3 & -3.9 \\ 1.7 & 4.3 & -2.7 & 2 & 2.5 & 4.6 & 4.6 & -4.5 \end{bmatrix}$	$\begin{bmatrix} 1 & 0 & 1 & 1 & 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}$

1 Исходный код

Лабораторная работа № 1

Вариант: 9

```
[1]: import numpy as np
     from tensorflow import keras
     import tensorflow as tf
     import matplotlib
     import matplotlib.pyplot as plt
     from matplotlib.colors import from_levels_and_colors, LinearSegmentedColormap
     from matplotlib.markers import MarkerStyle
[2]: %matplotlib inline
     import matplotlib_inline
     matplotlib_inline.backend_inline.set_matplotlib_formats('svg', 'pdf')
[3]: COLORS = ['red', 'green', 'purple', 'yellow']
     def plot_history(h, *metrics):
         for metric in metrics:
             print(f"{metric}: {h.history[metric][-1]:.4f}")
         figure = plt.figure(figsize=(5 * len(metrics), 3))
         for i, metric in enumerate(metrics, 1):
             ax = figure.add_subplot(1, len(metrics), i)
             ax.xaxis.get_major_locator().set_params(integer=True)
             plt.title(metric)
             plt.plot(h.history[metric], '-')
         plt.show()
     def plot_line(a, b, c):
         xlim, ylim = plt.xlim(), plt.ylim()
         plt.axline((-c / a, 0), slope=-a/b)
         plt.xlim(xlim)
         plt.ylim(ylim)
```

Классификация объектов двух классов

```
def plot_two_classes_decision_regions(model, n=100):
    x_min, x_max = plt.xlim()
    y_min, y_max = plt.ylim()


x = np.linspace(x_min, x_max, n)
    y = np.linspace(y_min, y_max, n)

xv, yv = np.meshgrid(x, y)
    z = model.predict(np.c_[xv.ravel(), yv.ravel()]).reshape(n, n)

cmap = LinearSegmentedColormap.from_list('cmap', COLORS[:2])


plt.contourf(x, y, z, alpha=0.4, cmap=cmap, levels=10)
```

[6]: plot_two_classes(data1, labels1) plt.show()




[8]: plot_history(hist1, 'accuracy', 'mae')

accuracy: 1.0000 mae: 0.0143




```
[9]: weights1 = model1.get_weights()
```


[10]: plot_two_classes(data1, labels1) plot_line(weights1[0][0][0], weights1[0][1][0], weights1[1][0]) plt.show()



```
[11]: plot_two_classes(data1, labels1)
   plot_line(weights1[0][0][0], weights1[0][1][0], weights1[1][0])
   plot_two_classes_decision_regions(model1)
   plt.show()
```



Тестирование




Линейно неразделимый случай

```
[15]: x = np.linspace(-1.5, 1.3, 10) + (0.6 * np.random.random(10) - 0.3)
y = (x ** 2) + (0.6 * np.random.random(10) - 0.3)
data_nonlin = np.stack((x, y), axis=-1)
labels_nonlin = np.ones((10, ), dtype=int)

x = np.linspace(0, 1, 10) + (0.4 * np.random.random(10) - 0.2)
y = (2 * x + 1) + (0.6 * np.random.random(10) - 0.3)
data_nonlin = np.append(data_nonlin, np.stack((x, y), axis=-1), axis=0)
labels_nonlin = np.append(labels_nonlin, np.zeros((10, ), dtype=int))
```


[16]: plot_two_classes(data_nonlin, labels_nonlin)



```
model1_2.compile(keras.optimizers.Adam(0.01), 'mse', ['mae', 'accuracy'])
hist1_2 = model1_2.fit(data_nonlin, labels_nonlin, batch_size=1, epochs=100, userbose=0)
```


[18]: plot_history(hist1_2, 'accuracy', 'mae')

accuracy: 0.8000 mae: 0.3154



[19]: weights1_2 = model1_2.get_weights()


[20]: plot_two_classes(data_nonlin, labels_nonlin) plot_line(weights1_2[0][0][0], weights1_2[0][1][0], weights1_2[1][0]) plot_two_classes_decision_regions(model1_2) plt.show()



Классификация объектов четырех классов

```
[21]: data2 = np.array([(4.6, 1.7), (-1, 4.3), (-0.3, -2.7), (-1.1, 2), (0.5, 2.5), (4.9, 1.7))
       \rightarrow4.6), (0.3, 4.6), (-3.9, -4.5)])
      labels2 = np.array([(1, 1), (0, 0), (1, 1), (1, 0), (1, 0), (1, 0), (0, 0), (1, 1)])
[22]: def plot_four_classes(data, labels, test=False):
          colors = [COLORS[i[0] * 2 + i[1]] for i in labels]
          plt.scatter(data[:, 0], data[:, 1], c=colors, marker=MarkerStyle('o', 'none' ifu
       ⇔test else 'full'))
      def accuracy_bin_encoded(labels, pred):
          """Calculates how often predictions match binary encoded labels"""
          correct = 0
          threshold = tf.constant([0.5])
          for i in range(len(labels)):
              if tf.experimental.numpy.all(tf.equal(tf.greater_equal(pred[i], threshold), _ u
       →tf.cast(labels[i], tf.bool))):
                  correct += 1
          return correct / len(labels)
```


[23]: plot_four_classes(data2, labels2)
plt.show()




```
[25]: plot_history(hist2, 'accuracy_bin_encoded', 'mae')
```


accuracy_bin_encoded: 1.0000

mae: 0.0888






```
[26]: weights2 = model2.get_weights()
```



```
[28]: plot_four_classes(data2, labels2)
    plot_line(weights2[0][0][0], weights2[0][1][0], weights2[1][0])
    plot_line(weights2[0][0][1], weights2[0][1][1], weights2[1][1])

    x_min, x_max = plt.xlim()
    y_min, y_max = plt.ylim()

    n = 200
```



Тестирование

test_labels2

```
[41]: test_size = 5

max_x, max_y = np.max(data2, axis=0)
min_x, min_y = np.min(data2, axis=0)


test_x = (max_x - min_x) * np.random.random(test_size) + min_x
test_y = (max_y - min_y) * np.random.random(test_size) + min_y

test2 = np.stack([test_x, test_y], axis=-1)
[42]: test_labels2 = model2.predict(test2)
```

```
[42]: array([[7.5612509e-01, 3.5026193e-02], [9.9985087e-01, 9.9992895e-01], [7.9546034e-02, 1.1077945e-04], [9.6717298e-01, 4.9302673e-01],
```

[8.9885688e-01, 2.2142953e-01]], dtype=float32)

```
[43]: plot_four_classes(data2, labels2)
plot_four_classes(test2, (test_labels2 >= 0.5).astype(int), test=True)
plot_line(weights2[0][0][0], weights2[0][1][0], weights2[1][0])
plot_line(weights2[0][0][1], weights2[0][1][1], weights2[1][1])
```



2 Выводы

В ходе выполнения первой лабораторной работы я освежил свои знания про перцептрон Розенблата. Применительно к задачам классификации единичный перцептрон показывает хорошие результаты только в линейно разделимом случае, что накладывает сильные ограничения на входные данные. Однако, он легко обобщается на случай многоклассовой классификации.