# Московский авиационный институт (национальный исследовательский университет)

Институт №8 «Информационные технологии и прикладная математика»

Кафедра 806 «Вычислительная математика и программирование»

Лабораторная работа №4 по курсу «Нейроинформатика»

Студент: В.В. Бирюков Преподаватель: И.А. Рожлейс

Группа: М8О-407Б-19

Дата: Оценка: Подпись:

# Лабораторная работа №4

Тема: Сети с радиальными базисными элементами.

**Цель работы:** Исследование свойств некоторых видов сетей с радиальными базисными элементами, алгоритмов обучения, а также применение сетей в задачах классификации и аппроксимации функции.

### Основные этапы работы:

- 1. Использовать сеть с радиальными базисными элементами (RBF) для классификации точек в случае, когда классы не являются линейно разделимыми.
- 2. Использовать обобщенно-регрессионную нейронную сеть для аппроксимации функции.

#### Вариант: 9

#### Алгебраические линии:

• Эллипс:  $a = 0.2, b = 0.2, \alpha = 0, x_0 = -0.2, y_0 = 0$ 

• Эллипс: a = 0.7, b = 0.5,  $\alpha = -\pi/3$ ,  $x_0 = 0$ ,  $y_0 = 0$ 

• Эллипс:  $a = 1, b = 1, \alpha = 0, x_0 = 0, y_0 = 0$ 

Функция:  $x = \sin(t^2 - 2t + 5)$ 

## 1 Исходный код

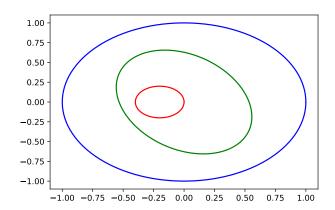
### Лабораторная работа № 4

#### Вариант: 9

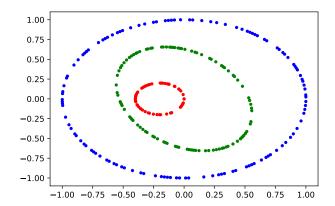
```
[1]: import numpy as np
     from numpy import sin, cos, pi
     from tensorflow import keras
     from keras import backend
     import matplotlib.pyplot as plt
     from sklearn.model_selection import train_test_split
     from matplotlib.colors import LinearSegmentedColormap
[2]: %matplotlib inline
     import matplotlib_inline
     matplotlib_inline.backend_inline.set_matplotlib_formats('png', 'pdf')
[3]: def plot_history(h, *metrics):
         for metric in metrics:
             print(f"{metric}: {h.history[metric][-1]:.4f}")
         figure = plt.figure(figsize=(6 * len(metrics), 4))
         for i, metric in enumerate(metrics, 1):
             ax = figure.add_subplot(1, len(metrics), i)
             ax.xaxis.get_major_locator().set_params(integer=True)
             plt.title(metric)
             plt.plot(h.history[metric], '-')
         plt.show()
[4]: class RBFLayer(keras.layers.Layer):
         def __init__(self, output_dim, mu_init='uniform', sigma_init='random_normal',_
      →**kwargs):
             self.output_dim = output_dim
             self.mu_init = mu_init
             self.sigma_init = sigma_init
             super(RBFLayer, self).__init__(**kwargs)
         def build(self, input_shape):
             self.mu = self.add_weight(name='mu', shape=(input_shape[1], self.
      →output_dim), initializer=self.mu_init, trainable=True)
             self.sigma = self.add_weight(name='sigma', shape=(self.output_dim,),_
      →initializer=self.sigma_init, trainable=True)
             super(RBFLayer, self).build(input_shape)
         def call(self, inputs):
             diff = backend.expand_dims(inputs) - self.mu
             output = backend.exp(backend.sum(diff ** 2, axis=1) * self.sigma)
             return output
```

#### Классификация

```
[5]: def ellipse(t, a, b, x0, y0, alpha):
         x = a * cos(t)
         y = b * sin(t)
         x, y = rotate(x, y, alpha)
         return np.array((x + x0, y + y0)).T
     def rotate(x, y, alpha):
         xr = x * cos(alpha) - y * sin(alpha)
         yr = x * sin(alpha) + y * cos(alpha)
         return xr, yr
[6]: def plot_three_classes(data, labels, colors):
         plt.scatter(data1[:, 0], data1[:, 1], c=[colors[i[1]+i[2]*2] for i in labels1],__
     →marker='.')
     COLORS = ['red', 'green', 'blue']
[7]: a1 = 0.2; b1 = 0.2; alpha1 = 0;
                                           x01 = -0.2; y01 = 0
     a2 = 0.7; b2 = 0.5; alpha2 = -pi / 3; x02 = 0;
                                                       y02 = 0
                                                       y03 = 0
                         alpha3 = 0;
     a3 = 1; b3 = 1;
                                           x03 = 0;
[8]: t = np.arange(0, 2 * pi, 0.025)
     ellipse1 = ellipse(t, a1, b1, x01, y01, alpha1)
     ellipse2 = ellipse(t, a2, b2, x02, y02, alpha2)
     ellipse3 = ellipse(t, a3, b3, x03, y03, alpha3)
[9]: plt.plot(ellipse1[:, 0], ellipse1[:, 1], COLORS[0])
     plt.plot(ellipse2[:, 0], ellipse2[:, 1], COLORS[1])
     plt.plot(ellipse3[:, 0], ellipse3[:, 1], COLORS[2])
     plt.show()
```



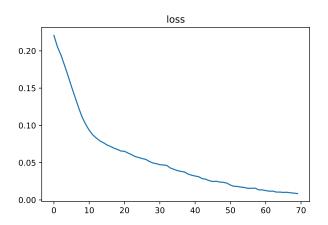
[11]: plot\_three\_classes(data1, labels1, COLORS) plt.show()



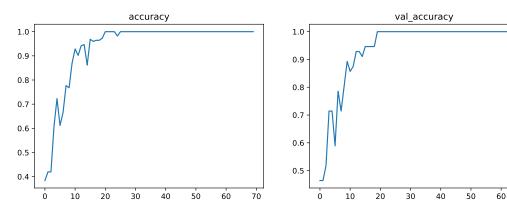
```
[12]: train_data1, test_data1, train_labels1, test_labels1 = train_test_split(data1,u -- labels1, train_size=0.8)
```

```
[14]: plot_history(hist1, 'loss')
   plot_history(hist1, 'accuracy', 'val_accuracy')
```

loss: 0.0085



accuracy: 1.0000 val\_accuracy: 1.0000

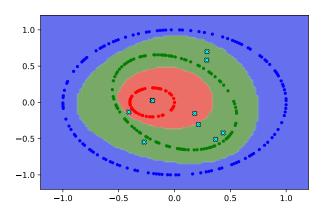


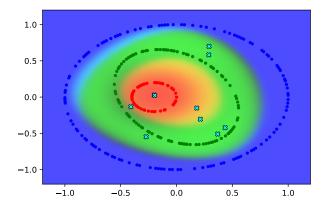
70

```
[15]: n = 100
x = np.linspace(-1.2, 1.2, n)
y = np.linspace(-1.2, 1.2, n)

xv, yv = np.meshgrid(x, y)
z = model1.predict(np.c_[xv.ravel(), yv.ravel()]).argmax(axis=1).reshape(n, n)

cmap = LinearSegmentedColormap.from_list('cmap', COLORS)
plt.contourf(xv, yv, z, alpha = 0.6, cmap=cmap)
plot_three_classes(train_data1, train_labels1, COLORS)
mu = model1.get_layer(index=0).get_weights()[0]
plt.scatter(mu[0], mu[1], marker='X', color='cyan', edgecolors='black', lw=0.3)
plt.show()
```



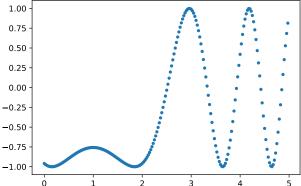


## Аппроксимация

```
[17]: def f(t):
    return sin(t ** 2 - 2 * t + 5)

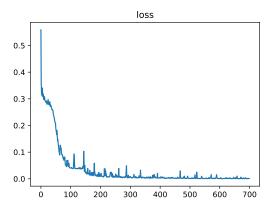
[18]: h = 0.025
    train_data2 = np.arange(0, 5, h)
    train_labels2 = f(train_data2)

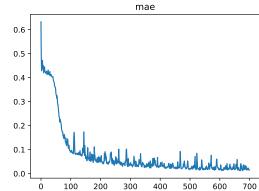
[19]: plt.plot(train_data2, train_labels2, '.')
    plt.show()
```



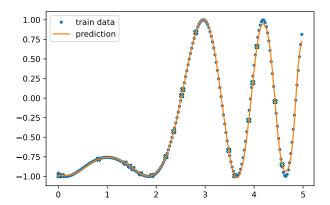
[41]: plot\_history(hist2, 'loss', 'mae')

loss: 0.0009 mae: 0.0155



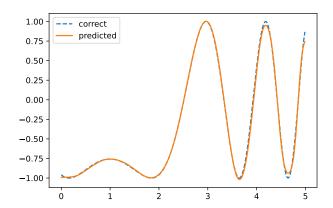


```
[42]: plt.plot(train_data2, train_labels2, '.', label='train data')
   plt.plot(train_data2, model2.predict(train_data2).flat, label='prediction')
   mu = model2.get_layer(index=0).get_weights()[0][0]
   mu_y = model2.predict(mu)
   plt.scatter(mu, mu_y.flat, marker='X', color='cyan', edgecolors='black', lw=0.3)
   plt.legend()
   plt.show()
```



```
[43]: test_data2 = np.arange(0, 5, h / 2)
    test_labels2 = f(test_data2)

plt.plot(test_data2, test_labels2, '--', label='correct')
    plt.plot(test_data2, model2.predict(test_data2).flat, label='predicted')
    plt.legend()
    plt.show()
```



# 2 Выводы

В ходе выполнения лабораторной работы я познакомился с сетями с радиальными базисными элементами. RBF слой вводит дополнительную нелинейность в нейронную сеть, что позволяет использовать меньшее число линейных слоев для окончательной классификации (аппроксимации).